



Preditiva.ai

# Noções de Inferência Estatística

## Introdução aos

## Testes de Hipóteses


# Noções de Inferência Estatística

## Introdução aos Testes de Hipóteses



Os **Testes de Hipóteses** são uma técnica de **Inferência** muito importante para realizar **comparações** dos dados amostrais com valores de referência ou dados de outras amostras.

Uma característica fundamental nos **Testes de Hipóteses** é a de realizar essas comparações considerando, além das medidas resumo, a **distribuição de probabilidades** do fenômeno estudado e as **incertezas** relacionadas a utilização de uma amostra.



# Noções de Inferência Estatística


## Introdução aos Testes de Hipóteses



Por essa grande relevância, os **Testes de Hipóteses** estão muito presentes em nosso dia a dia, em aplicações como por exemplo:

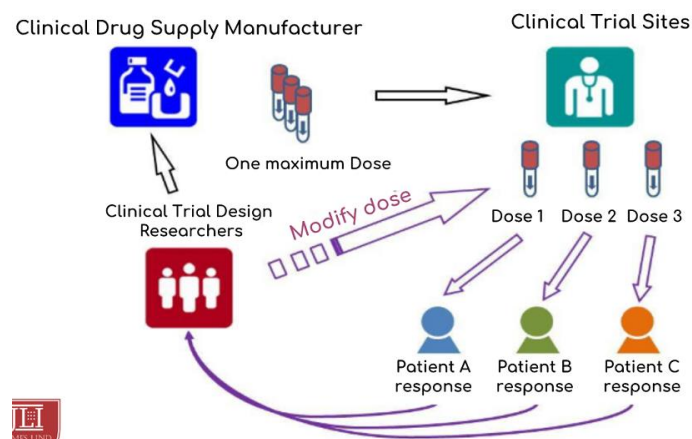
### Testes A/B

Comparação do efeito de duas campanhas diferentes de marketing.




### Estudos Clínicos

Medicamento vs. Placebo,  
Tratamento A vs.  
Tratamento B.



### Melhoria Contínua

Desempenho do novo  
processo vs. processo antigo.





Preditiva.ai

# Noções de Inferência Estatística

## Testes de Hipóteses

## Média de uma população

# Noções de Inferência Estatística

## Teste de Hipóteses: Média de uma população



Uma empresa responsável por realizar testes de qualidade nas águas das represas que abastecem a região metropolitana da cidade de São Paulo coletou **100 amostras de água da represa Billings**. Após realizar a análise de pH, a empresa obteve os seguintes dados:

Represa	Nº Amostras	pH	
		Média	Desvio Padrão
Billings	100	5,8	1,4

Como a Legislação Brasileira define que apenas águas com o **pH entre 6 e 9 sejam utilizadas no abastecimento**, surgiu a seguinte pergunta:

Deve-se **suspender o fornecimento de água** das regiões abastecidas pela represa Billings?



# Noções de Inferência Estatística


## Teste de Hipóteses: Média de uma população



**Lembre-se:** como estamos analisando **dados de uma amostra**, devemos utilizar corretamente as **técnicas de inferência** para tomarmos a **melhor decisão**. E neste caso, devemos utilizar os **Testes de Hipóteses** para realizar essa comparação corretamente.

Represa	Nº Amostras	pH	
		Média	Desvio Padrão
Billings	100	5,8	1,4

Como queremos **comparar a Média do pH** medido nas 100 amostras com um **valor de referência** e o histograma do pH se assemelha a uma **distribuição Normal**, o **Teste de Hipóteses** mais adequado é o **Teste-t**.



# Noções de Inferência Estatística

## Teste de Hipóteses: Média de uma população



### 1º Passo: Definir as Hipóteses

A partir da pergunta que desejamos responder, definimos as **hipóteses que serão testadas**.

Teremos sempre:

$H_0$  ou **Hipótese nula**

$H_1$  ou **Hipótese alternativa**

Para responder a pergunta se deve-se ou não suspender o abastecimento de água, precisamos saber se a **média do pH medido a partir das 100 amostras é estatisticamente igual a 6 ou inferior a 6**.

A **Hipótese Nula** sempre apresentará uma **igualdade**, pois é sob essa condição que calculamos a **estatística do teste**. Já a **Hipótese Alternativa** sempre apresentará uma **desigualdade**.

Dessa forma, teremos as seguintes hipóteses **nula** e **alternativa**:

$H_0$ : O pH das águas da represa Billings é igual a 6, ou: **pH = 6**

$H_1$ : O pH das águas da represa Billings é inferior a 6, ou: **pH < 6**



# Noções de Inferência Estatística

## Teste de Hipóteses: Média de uma população



### 2º Passo: Calcular a estatística do teste

Cada **Teste de Hipóteses** possui sua própria **estatística de teste**, que é um cálculo realizado com os **dados da amostra**.

Como utilizaremos o **Teste-t**, sua **estatística de teste** é definida pela equação abaixo:

$$T = \frac{\sqrt{n}(\bar{X} - \mu_0)}{S}$$

**n**: tamanho da amostra

$\bar{X}$ : média amostral

$\mu_0$ : média sob a hipótese  $H_0$

**S**: desvio padrão amostral

Realizando o cálculo com os dados que obtivemos das 100 amostras, temos:

$$T = \frac{\sqrt{n}(\bar{X} - \mu_0)}{S} = \frac{\sqrt{100}(5,8 - 6)}{1,4} = -1,43$$



# Noções de Inferência Estatística

## Teste de Hipóteses: Média de uma população




### 3º Passo: Calcular o p-valor

Cada **estatística de teste** possui uma **distribuição de probabilidades**. A partir dela e das hipóteses calculamos o **p-valor**, que é uma medida de **quão plausível é  $H_0$** .

A **estatística do Teste-t** possui uma **distribuição** de probabilidade **t-Student** com  $n-1$  graus de liberdade. É essa distribuição que utilizaremos para calcular o **quão plausível é a hipótese nula**.

Além da distribuição da estatística do teste, usamos também a **hipótese alternativa**, pois **dependendo da desigualdade** definida, calcularemos regiões diferentes da distribuição t-Student.



# Noções de Inferência Estatística

## Teste de Hipóteses: Média de uma população



### 3º Passo: Calcular o p-valor


Cada **estatística de teste** possui uma **distribuição de probabilidades**. A partir dela e das hipóteses calculamos o **p-valor**, que é uma medida de **quão plausível é  $H_0$** .

Relembrando as hipóteses definidas:


$H_0$ : O pH das águas da represa Billings é igual a 6, ou: **pH = 6**

$H_1$ : O pH das águas da represa Billings é inferior a 6, ou: **pH < 6**

Como a hipótese alternativa foi definida como "<", calcularemos o **p-valor** na cauda esquerda da **distribuição** de probabilidade **t-Student** com 99 graus de liberdade.



Para o cálculo, vamos utilizar a função **DIST.T** do Excel:

 **DIST.T(T; n-1; VERDADEIRO)**

**DIST.T(-1,43; 99; VERDADEIRO) = 0,078**

# Noções de Inferência Estatística

## Teste de Hipóteses: Média de uma população



### 4º Passo: Comparar e tomar decisão

Por fim, comparamos o **p-valor** com um **nível de significância** para concluir se **rejeitamos** ou **não rejeitamos** a hipótese  $H_0$ .

Agora vamos comparar o **p-valor** calculado de **7,8%** com a **Escala de significância de Fisher**:

Nível significância	10%	5%	2,5%	1%	0,5%	0,1%
Evidências contra $H_0$	Marginal	Moderada	Substancial	Forte	Muito forte	Fortíssima

O valor de **7,8%** fica localizado entre "**Marginal**" e "**Moderada**", o que significa que as **evidências contra  $H_0$  não são tão fortes**.

Como regra geral, **compara-se o p-valor com o nível de significância de 5%**:

- **P-valor inferior a 5%: rejeição** da hipótese nula ( $H_0$ )
- **P-valor superior a 5%: não rejeição** da hipótese nula ( $H_0$ )

# Noções de Inferência Estatística

## Teste de Hipóteses: Média de uma população



### 4º Passo: Comparar e tomar decisão

Por fim, comparamos o **p-valor** com um **nível de significância** para concluir se **rejeitamos** ou **não rejeitamos** a hipótese  $H_0$ .

Como o **p-valor** de **7,8%** é maior do que o **nível de significância** de 5%, podemos concluir então que **não existem evidências estatísticas suficientes contra  $H_0$** , ou seja, **não rejeitamos  $H_0$** .

Relembrando as hipóteses definidas:

$H_0$ : O pH das águas da represa Billings é igual a 6, ou: **pH = 6**

$H_1$ : O pH das águas da represa Billings é inferior a 6, ou: **pH < 6**

E como **não rejeitamos  $H_0$** , podemos dizer que **não existem evidências estatísticas** de que o **pH das águas da represa Billings não seja igual a 6**.

Portanto, **não é necessário suspender o fornecimento de água** das regiões abastecidas pela represa Billings.

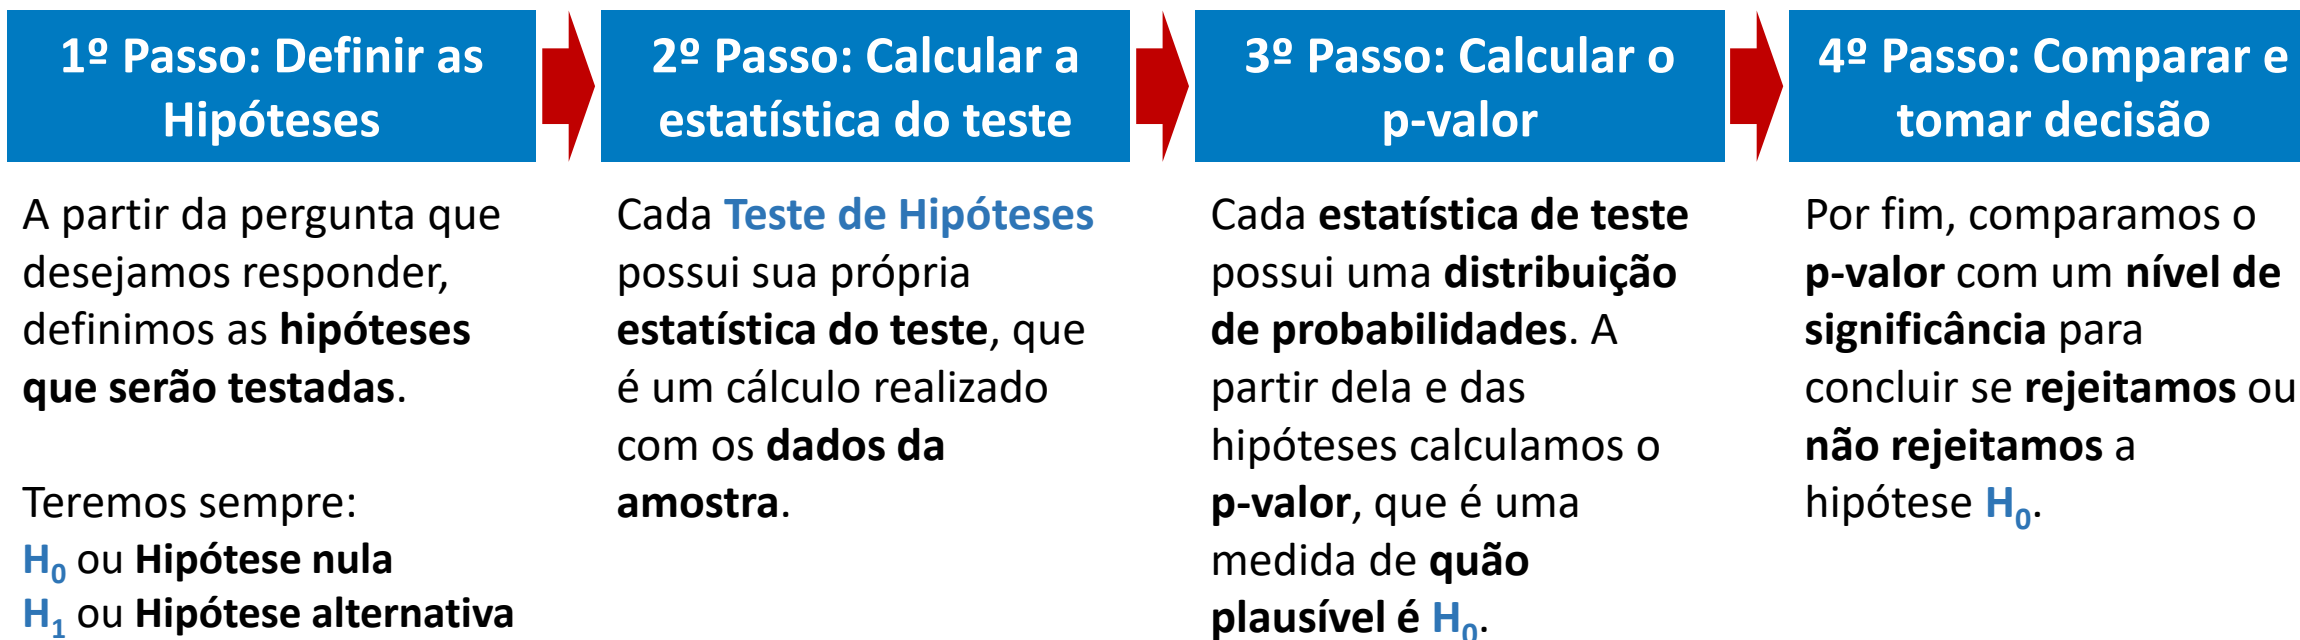
# Noções de Inferência Estatística

## Estrutura dos Testes de Hipóteses



Os **4 passos** que acabamos de realizar constituem o método de aplicação dos **Testes de Hipóteses**, e serão sempre os mesmos para qualquer **Teste de Hipóteses**.

Entender o conceito de cada passo te possibilitará utilizar qualquer **Teste de Hipóteses**, afinal existem muitos, cada um adequado para atender uma necessidade de análise.



# Noções de Inferência Estatística

## Teste de Hipóteses: Média de uma população

O que significa rejeitar ou não rejeitar  $H_0$ ?



### 2 Hipóteses:

Culpado ou Inocente?



### Levantamento:

Conjunto de provas (evidências)



### Decisão:

Evidências suficientes → Culpado

Não há evidências suficientes → Inocente





Preditiva.ai

# Noções de Inferência Estatística

## Testes de Hipóteses

### Média e Variância de duas populações



# Noções de Inferência Estatística

## Teste de Hipóteses: Média de duas populações



A mesma empresa responsável pelos testes de qualidade nas águas das represas coletou agora **110 amostras de água da represa Guarapiranga**, realizou as mesmas análises de pH, e obteve os dados descritos na tabela abaixo:

Represa	Nº Amostras	pH	
		Média	Desvio Padrão
Billings	100	5,8	1,4
Guarapiranga	110	6,3	1,5

O órgão de fiscalização suspeita que o pH das águas da represa Guarapiranga seja **superior** ao pH das águas da represa Billings, e solicitou a empresa um **estudo para confirmação**.




# Noções de Inferência Estatística

## Teste de Hipóteses: Média de duas populações



Por estarmos trabalhando com **amostras** e querermos fazer a **comparação** dos valores dessas populações, precisamos utilizar os **Testes de Hipóteses** para dar uma **resposta confiável** para a pergunta: as águas da Guarapiranga possuem um pH superior as águas da Billings?

Represa	Nº Amostras	pH	
		Média	Desvio Padrão
Billings	100	5,8	1,4
Guarapiranga	110	6,3	1,5



Como o **histograma das amostras** da represa Guarapiranga também se assemelha a uma **distribuição Normal**, vamos utilizar o **Teste-t para duas populações**.

# Noções de Inferência Estatística

## Teste de Hipóteses: Média de duas populações



### 1º Passo: Definir as Hipóteses

A partir da pergunta que desejamos responder, definimos as **hipóteses** que serão testadas.

Teremos sempre:

$H_0$  ou **Hipótese nula**

$H_1$  ou **Hipótese alternativa**

Para responder a pergunta precisamos saber se a **média do pH da represa**

**Guarapiranga é estatisticamente maior** do que a **média do pH da represa Billings**.

Como já sabemos que a **Hipótese Nula** sempre apresentará uma **igualdade** e a

**Hipótese Alternativa** uma **desigualdade**, definimos as seguintes hipóteses **nula** e

**alternativa**:

$H_0$ : O pH da Guarapiranga é **igual** ao pH da Billings, ou:  $pH_G = pH_B$

$H_1$ : O pH da Guarapiranga é **superior** ao pH da Billings, ou:  $pH_G > pH_B$

# Noções de Inferência Estatística

## Teste de Hipóteses: Média de duas populações



### 2º Passo: Calcular a estatística do teste

Cada **Teste de Hipóteses** possui sua própria **estatística de teste**, que é um cálculo realizado com os **dados da amostra**.

### 3º Passo: Calcular o p-valor

Cada **estatística de teste** possui uma **distribuição de probabilidades**. A partir dela e das hipóteses calculamos o **p-valor**, que é uma medida de **quão plausível é  $H_0$** .

No caso do **Teste-t para 2 populações**, o Excel possui a função **TESTE.T** que calcula a **estatística de teste** e o **p-valor** em apenas 1 passo.

pH Billings	pH Guarapiranga
4,59	7,88
5,64	5,43
3,28	6,52
4,63	6,75
6,93	7,11
7,30	7,23
7,89	3,95
5,22	5,02

 **TESTE.T(matriz 1; matriz 2; caudas; tipo)**

**caudas:** 1: unicaudal ou 2: bicaudal

**tipo:** 1: par, 2: variâncias iguais ou 3: variâncias diferentes

Em **caudas**, quando  $H_1$  é "<" ou ">" escolhemos **unicaudal**, e quando  $H_1$  é "≠" escolhemos **bicaudal**. Como o  $H_1$  definido é ">", utilizaremos **"1"** para indicar a opção **unicaudal**.

Já em **tipo**, indicamos qual o tipo do teste. A opção "par" não se aplica neste caso (veremos mais adiante), mas vamos precisar escolher entre **"variâncias iguais"** e

**"variâncias diferentes"**.

# Noções de Inferência Estatística

## Teste de Hipóteses: Média de duas populações



### 2º Passo: Calcular a estatística do teste

Cada **Teste de Hipóteses** possui sua própria **estatística de teste**, que é um cálculo realizado com os **dados da amostra**.

### 3º Passo: Calcular o p-valor

Cada **estatística de teste** possui uma **distribuição de probabilidades**. A partir dela e das hipóteses calculamos o **p-valor**, que é uma medida de **quão plausível é  $H_0$** .

No caso do **Teste-t para 2 populações**, o Excel possui a função **TESTE.T** que calcula a **estatística de teste** e o **p-valor** em apenas 1 passo.

pH Billings	pH Guarapiranga
4,59	7,88
5,64	5,43
3,28	6,52
4,63	6,75
6,93	7,11
7,30	7,23
7,89	3,95
5,22	5,02

 **TESTE.T(matriz 1; matriz 2; caudas; tipo)**

**caudas:** 1: unicaudal ou 2: bicaudal

**tipo:** 1: par, 2: variâncias iguais ou 3: variâncias diferentes

Para podermos escolher a **opção correta** correta, precisaremos fazer um **Teste de Hipóteses** para testar se as **variâncias do pH** das águas das duas represas **podem ser consideradas iguais**. Para isso, vamos fazer uma pausa neste teste de média e aplicar o **Teste-F** que é utilizado para avaliar se as **duas variâncias podem ser consideradas iguais** quando as amostras possuem **distribuição** semelhante a **Normal**.

# Noções de Inferência Estatística

## Teste de Hipóteses: Variância de duas populações



### 1º Passo: Definir as Hipóteses

A partir da pergunta que desejamos responder, definimos as **hipóteses que serão testadas**.

Teremos sempre:

$H_0$  ou **Hipótese nula**

$H_1$  ou **Hipótese alternativa**

Como queremos saber exatamente se as **variâncias do pH** das águas das duas represas **podem ser consideradas iguais**, definimos as seguintes hipóteses **nula** e **alternativa**:

$H_0$ : As variâncias do pH da Billings e Guarapiranga são **iguais**, ou:  $\text{Var}_{\text{pHG}} = \text{Var}_{\text{pHB}}$

$H_1$ : As variâncias do pH da Billings e Guarapiranga são **diferentes**, ou:  $\text{Var}_{\text{pHG}} \neq \text{Var}_{\text{pHB}}$



# Noções de Inferência Estatística

## Teste de Hipóteses: Variância de duas populações



### 2º Passo: Calcular a estatística do teste

Cada **Teste de Hipóteses** possui sua própria **estatística de teste**, que é um cálculo realizado com os **dados da amostra**.

### 3º Passo: Calcular o p-valor

Cada **estatística de teste** possui uma **distribuição de probabilidades**. A partir dela e das hipóteses calculamos o **p-valor**, que é uma medida de **quão plausível é  $H_0$** .

No caso do **Teste-F**, o Excel possui a função **TESTE.F** que calcula a **estatística de teste** e o **p-valor** em apenas 1 passo.

pH Billings	pH Guarapiranga
4,59	7,88
5,64	5,43
3,28	6,52
4,63	6,75
6,93	7,11
7,30	7,23
7,89	3,95
5,22	5,02



**TESTE.F(matriz 1; matriz 2)**

**TESTE.F(matriz 1 ; matriz 2) = 38,3%**

O resultado da função **TESTE.F** foi **38,3%**. Como o **p-valor** indica o **quão plausível é  $H_0$** , podemos antecipar que neste teste  **$H_0$  se mostra bastante plausível**.



# Noções de Inferência Estatística

## Teste de Hipóteses: Variância de duas populações



### 4º Passo: Comparar e tomar decisão

Por fim, comparamos o **p-valor** com um **nível de significância** para concluir se **rejeitamos** ou **não rejeitamos** a hipótese  $H_0$ .

Como o **p-valor** de **38,3%** é maior que o **nível de significância** de **5%**, podemos concluir que **não existem evidências estatísticas suficientes contra  $H_0$** , ou seja, **não rejeitamos  $H_0$** .

Relembrando as hipóteses definidas:

$H_0$ : As variâncias do pH da Billings e Guarapiranga são **iguais**, ou:  $\text{Var}_{\text{pHG}} = \text{Var}_{\text{pHB}}$

$H_1$ : As variâncias do pH da Billings e Guarapiranga são **diferentes**, ou:  $\text{Var}_{\text{pHG}} \neq \text{Var}_{\text{pHB}}$

E como **não rejeitamos  $H_0$** , podemos dizer que **não existem evidências estatísticas de que a variância do pH das águas das duas represas não sejam iguais**.

Portanto, devemos escolher a opção "**2: variâncias iguais**".

# Noções de Inferência Estatística

## Teste de Hipóteses: Média de duas populações



### 2º Passo: Calcular a estatística do teste

Cada **Teste de Hipóteses** possui sua própria **estatística de teste**, que é um cálculo realizado com os **dados da amostra**.

### 3º Passo: Calcular o p-valor

Cada **estatística de teste** possui uma **distribuição de probabilidades**. A partir dela e das hipóteses calculamos o **p-valor**, que é uma medida de **quão plausível é  $H_0$** .

Voltando a comparação das medias, sabemos agora que o tipo a ser informado é o **2**: **variâncias iguais**.

pH Billings	pH Guarapiranga
4,59	7,88
5,64	5,43
3,28	6,52
4,63	6,75
6,93	7,11
7,30	7,23
7,89	3,95
5,22	5,02

 **TESTE.T(matriz 1; matriz 2; caudas; tipo)**

**caudas**: 1: unicaudal ou 2: bicaudal

**tipo**: 1: par, 2: variâncias iguais ou 3: variâncias diferentes

**TESTE.T(matriz 1 ; matriz 2 ; 1 ; 2) = 0,7%**

O resultado da função **TESTE.F** foi **0,7%**. Como o **p-valor** indica o **quão plausível é  $H_0$** , podemos antecipar que neste teste  **$H_0$  se mostra pouco plausível**.

# Noções de Inferência Estatística

## Teste de Hipóteses: Média de duas populações



### 4º Passo: Comparar e tomar decisão

Por fim, comparamos o **p-valor** com um **nível de significância** para concluir se **rejeitamos** ou **não rejeitamos** a hipótese  $H_0$ .

Como o **p-valor** de **0,7%** é menor que o **nível de significância** de **5%**, podemos concluir que **existem evidências estatísticas suficientes contra  $H_0$** , ou seja, **rejeitamos  $H_0$** .

Relembrando as hipóteses definidas:

$H_0$ : O pH da Guarapiranga é **igual** ao pH da Billings, ou:  **$pH_G = pH_B$**

$H_1$ : O pH da Guarapiranga é **superior** ao pH da Billings, ou:  **$pH_G > pH_B$**

E como **rejeitamos  $H_0$** , podemos dizer que **existem evidências estatísticas** de que a **média do pH** das águas da **Guarapiranga é maior** do que a **média do pH** das águas da **Billings**.



Preditiva.ai

# Noções de Inferência Estatística

## Testes de Hipóteses

### Média de duas populações pareadas

# Noções de Inferência Estatística

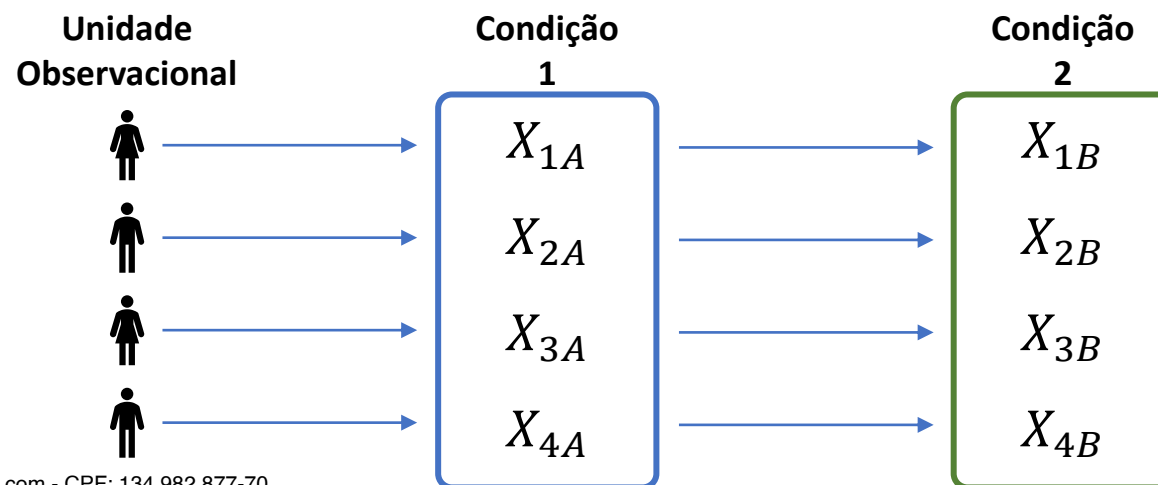
## Teste de Hipóteses: Média de duas populações pareadas



Um outro **Teste de Hipóteses** bastante útil é o **Teste-t Pareado**, muito utilizado para avaliar as mesmas unidades observacionais em diferentes condições. Por exemplo:

- Pessoas **antes** e **depois** de um tratamento.
- Desempenho de máquinas **antes** e **depois** de um ajuste.
- Produtividade de colaboradores em **home office** e no **escritório**.

Ou seja, o objetivo é avaliar se a **diferença entre as médias** nas diferentes condições **é igual a zero**.



# Noções de Inferência Estatística

## Teste de Hipóteses: Média de duas populações pareadas



Buscando reduzir custos e melhorar a qualidade de vida de seus colaboradores, uma empresa de atendimento decidiu fazer um **teste** para avaliar se a **adoção do home office** para os operadores produziria algum **efeito negativo** na qualidade dos atendimentos.

Para o teste foram **selecionados aleatoriamente** 30 operadores que tiveram as **médias das notas de avaliação** (0 a 10) dos clientes registradas nos **2 locais de trabalho**.

Com os **dados obtidos**, como podemos **responder a pergunta**: "Operadores trabalhando em home office possuem pior avaliação?"



Local de Trabalho	Nº Operadores	Avaliação dos clientes	
		Média	Desvio Padrão
Escritório	30	7,8	1,2
Home office		7,4	1,5

# Noções de Inferência Estatística

## Teste de Hipóteses: Média de duas populações pareadas



### 1º Passo: Definir as Hipóteses

A partir da pergunta que desejamos responder, definimos as **hipóteses** que serão testadas.

Teremos sempre:

$H_0$  ou **Hipótese nula**

$H_1$  ou **Hipótese alternativa**

Para responder a pergunta precisamos saber se a **média das notas dos clientes para os operadores trabalhando no escritório é estatisticamente maior** do que a **média das notas dos clientes para os mesmos operadores trabalhando em home office**.

Relembrando, a **Hipótese Nula** sempre apresentará uma **igualdade** e a **Hipótese Alternativa** uma **desigualdade**. Portanto definimos as seguintes hipóteses **nula** e **alternativa**:

$H_0$ : As notas no Escritório são **iguais** as notas em Home Office, ou:  $N_E = N_{HO}$

$H_1$ : As notas no Escritório são **maiores** que as notas em Home Office, ou:  $N_E > N_{HO}$



# Noções de Inferência Estatística

## Teste de Hipóteses: Média de duas populações pareadas



### 2º Passo: Calcular a estatística do teste

Cada **Teste de Hipóteses** possui sua própria **estatística de teste**, que é um cálculo realizado com os **dados da amostra**.

### 3º Passo: Calcular o nível descritivo

Cada **estatística de teste** possui uma **distribuição de probabilidades**. A partir dela e das hipóteses calculamos o **p-valor**, que é uma medida de **quão plausível é  $H_0$** .

No caso do **Teste-t para 2 populações pareadas**, o Excel possui a função **TESTE.T** que calcula a **estatística de teste** e o **p-valor** em apenas 1 passo.

Operador	Escritório	Home office
1	8,9	6,9
2	8,3	9,8
3	6,4	7,9
4	8,5	9,6
5	6,2	6,3
6	7,2	5,7
7	6,6	7,0
8	6,0	7,1

 **TESTE.T(matriz 1; matriz 2; caudas; tipo)**

**caudas**: 1: unicaudal ou 2: bicaudal

**tipo**: 1: par, 2: variâncias iguais ou 3: variâncias diferentes

**TESTE.T(matriz 1 ; matriz 2 ; 1 ; 1) = 12%**

Em **caudas**, como o  $H_1$  definido é ">", utilizaremos "1" para indicar a opção **unicaudal**.

Já em **tipo**, utilizaremos a opção "1" para indicar que as populações são **pareadas**.

Já sabemos que **p-valor** indica o **quão plausível é  $H_0$** , e neste caso, o valor calculado de **12%** indica que  **$H_0$  é plausível**.

# Noções de Inferência Estatística

## Teste de Hipóteses: Média de duas populações pareadas



### 4º Passo: Comparar e tomar decisão

Por fim, comparamos o **p-valor** com um **nível de significância** para concluir se **rejeitamos** ou **não rejeitamos** a hipótese  $H_0$ .

Como o **p-valor** de **12%** é maior que o **nível de significância** de **5%**, podemos concluir que **não existem evidências estatísticas suficientes contra  $H_0$** , ou seja, **não rejeitamos  $H_0$** .

Relembrando as hipóteses definidas:

$H_0$ : As notas no Escritório são **iguais** as notas em Home Office, ou:  $N_E = N_{HO}$

$H_1$ : As notas no Escritório são **maiores** que as notas em Home Office, ou:  $N_E > N_{HO}$

E como **não rejeitamos  $H_0$** , podemos dizer que **não existem evidências estatísticas** de que a **média das notas** dos operadores no **Escritório não seja igual** a **média das notas** dos mesmos operadores em **Home Office**.



Preditiva.ai

# Noções de Inferência Estatística

## Testes de Hipóteses

## Proporção de duas populações

# Noções de Inferência Estatística

## Teste de Hipóteses: Proporção de duas populações



Preditiva.ai

Com todos os esforços para combater o COVID-19, surgiram diversas iniciativas para desenvolver uma vacina **eficaz para reduzir o impacto dos sintomas**. Um laboratório em suas pesquisas chegou a **duas estratégias** viáveis:

1. Vírus enfraquecido
2. RNA mensageiro

Para decidir por qual estratégia seguir, realizou um estudo clínico com 87 pessoas distribuídas **aleatoriamente** entre as duas estratégias.

Com os resultados obtidos, como podemos **responder**: " Existe diferença na estratégia em relação à proporção de sintomas graves?"

Estratégia	Nº Amostras	Sintomas	
		Graves	Leves
Vírus enfraquecido	38	16%	84%
RNA mensageiro	50	28%	72%

# Noções de Inferência Estatística

## Teste de Hipóteses: Proporção de duas populações



### 1º Passo: Definir as Hipóteses

A partir da pergunta que desejamos responder, definimos as **hipóteses** que serão testadas.

Teremos sempre:

$H_0$  ou **Hipótese nula**

$H_1$  ou **Hipótese alternativa**

Para responder a pergunta precisamos saber se a **proporção** de pessoas com sintomas graves tendo sido vacinadas com o **vírus enfraquecido (VE)** é **estatisticamente diferente** da **proporção** de pessoas com sintomas graves que foram vacinadas **com o RNA mensageiro (RNA)**.

Definimos então as seguintes hipóteses **nula** e **alternativa**:

$H_0$ : A proporção sintomas graves VE é **igual** a proporção sintomas graves RNA, ou:

$$p_{VE} = p_{RNA}$$

$H_1$ : A proporção sintomas graves VE é **diferente** da proporção sintomas graves

RNA, ou:  $p_{VE} \neq p_{RNA}$

# Noções de Inferência Estatística

## Teste de Hipóteses: Proporção de duas populações



### 2º Passo: Calcular a estatística do teste

Cada **Teste de Hipóteses** possui sua própria **estatística de teste**, que é um cálculo realizado com os **dados da amostra**.

Para esta comparação utilizaremos o **Teste-Z para 2 populações**, que possui a seguinte **estatística de teste**:

$$Z = \frac{(\hat{p}_{VE} - \hat{p}_{RNA})}{\sqrt{\hat{p}(1 - \hat{p}) \left( \frac{1}{n_{VE}} + \frac{1}{n_{RNA}} \right)}}$$

$$\hat{p} = \frac{\hat{p}_{VE} \cdot n_{VE} + \hat{p}_{RNA} \cdot n_{RNA}}{n_{VE} + n_{RNA}}$$

$\hat{p}_{VE}$ : proporção sintomas graves - vírus enfraquecido

$\hat{p}_{RNA}$ : proporção sintomas graves - RNA mensageiro

$\hat{p}$  : proporção geral de sintomas graves

$n_{VE}$ : número de pessoas - vírus enfraquecido

$n_{RNA}$ : número de pessoas - RNA mensageiro

# Noções de Inferência Estatística


## Teste de Hipóteses: Proporção de duas populações



### 3º Passo: Calcular o p-valor

Cada **estatística de teste** possui uma **distribuição de probabilidades**. A partir dela e das hipóteses calculamos o **p-valor**, que é uma medida de **quão plausível é  $H_0$** .

A estatística do Teste-Z para 2 populações possui uma **distribuição** de probabilidade **Normal Padrão**. E como a **hipótese alternativa**, foi definida como " $\neq$ ", então o **p-valor** será calculado **somando** as probabilidades nas **duas caudas**.



 **DIST.NORMP.N(Z; VERDADEIRO)**

**DIST.NORMP.N(-1,35; VERDADEIRO) = 9%**

Multiplicando o **p-valor** calculado por 2, obtemos **18%**.



# Noções de Inferência Estatística

## Teste de Hipóteses: Proporção de duas populações



### 4º Passo: Comparar e tomar decisão

Por fim, comparamos o **p-valor** com um **nível de significância** para concluir se **rejeitamos** ou **não rejeitamos** a hipótese  $H_0$ .

Como o **p-valor** de **18%** é maior que o **nível de significância** de **5%**, podemos concluir que **não existem evidências estatísticas suficientes contra  $H_0$** , ou seja, **não rejeitamos  $H_0$** .

Relembrando as hipóteses definidas:

$H_0$ : A proporção sintomas graves VE é **igual** a proporção sintomas graves RNA

$H_1$ : A proporção sintomas graves VE é **diferente** da proporção sintomas graves RNA

E como **não rejeitamos  $H_0$** , podemos dizer que **não existem evidências estatísticas** de que a **proporção** de pessoas com sintomas graves **não é igual** nos 2 tipos de vacinas.



Preditiva.ai

# Noções de Inferência Estatística

## Testes de Hipóteses

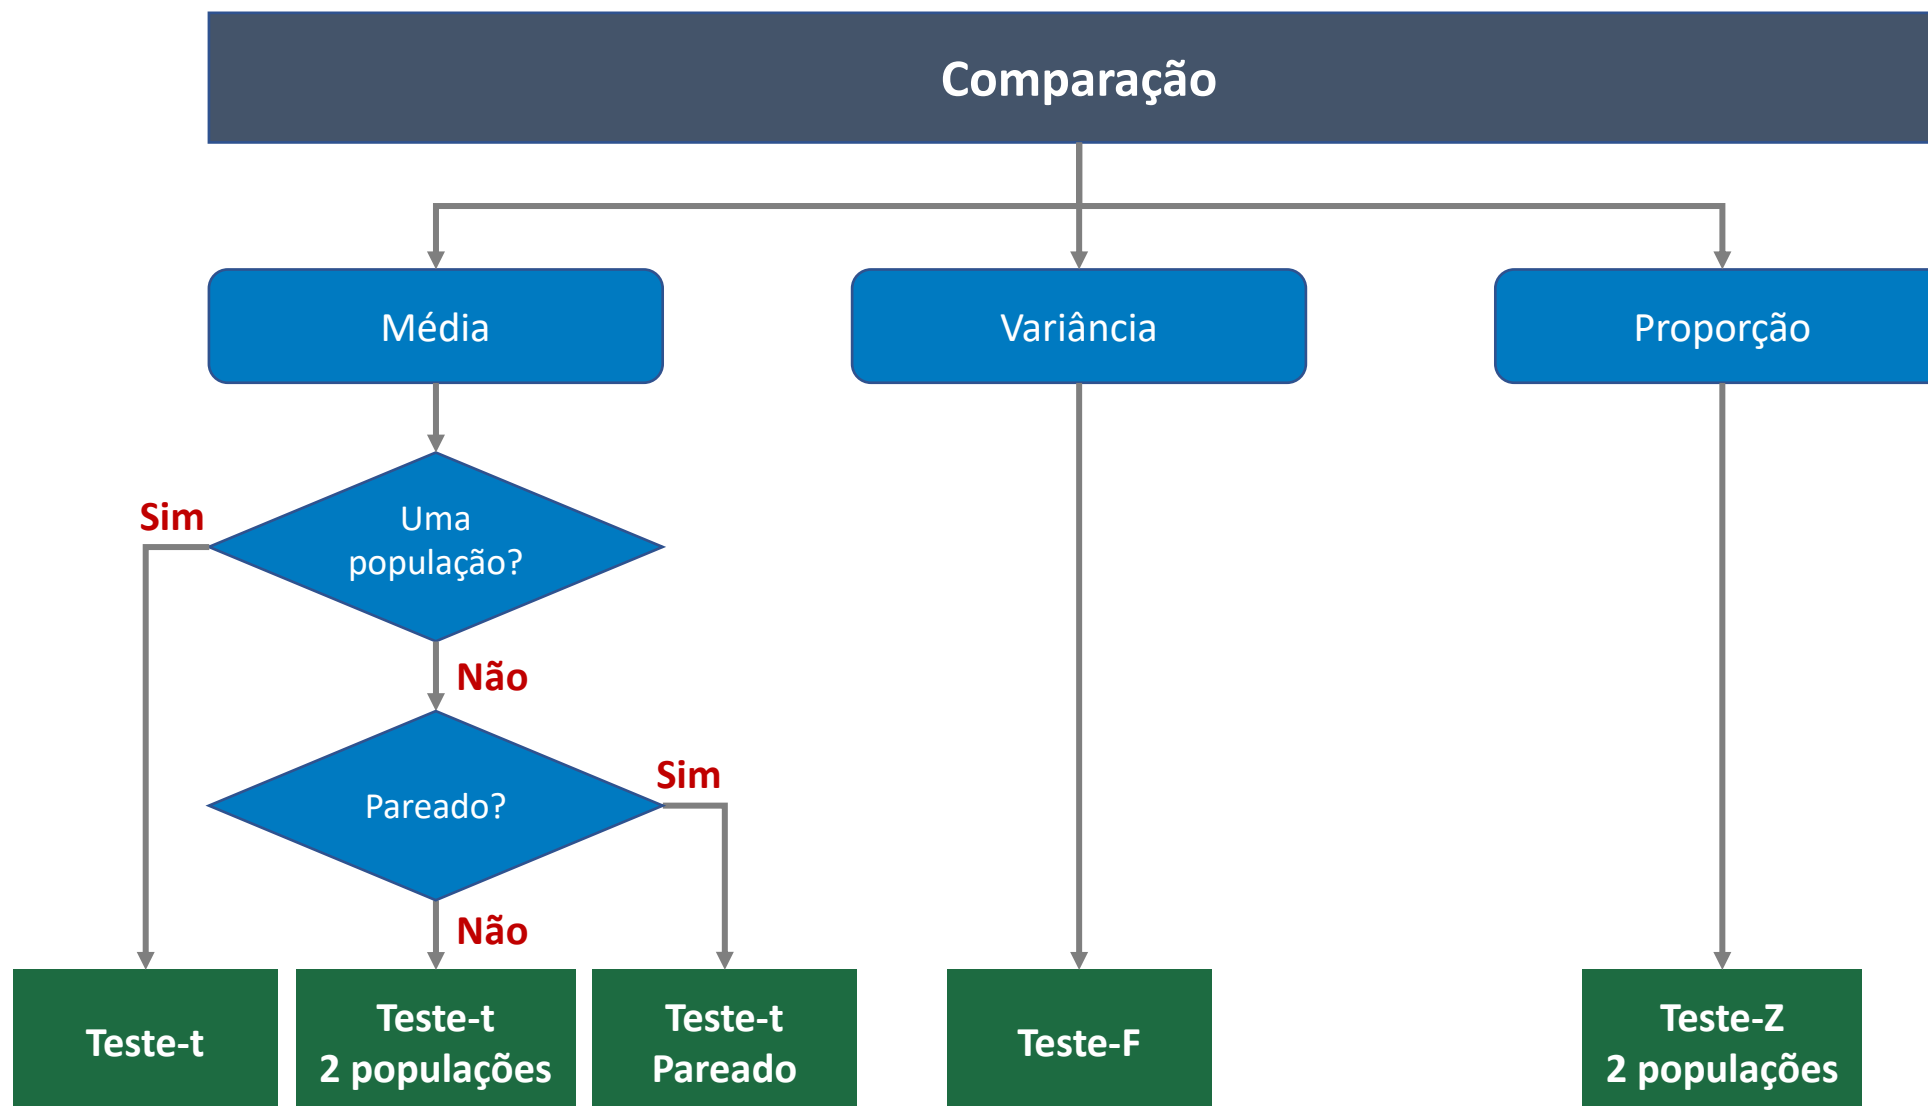
## Revisão

# Noções de Inferência Estatística

## Aplicações dos Testes de Hipóteses



Preditiva.ai

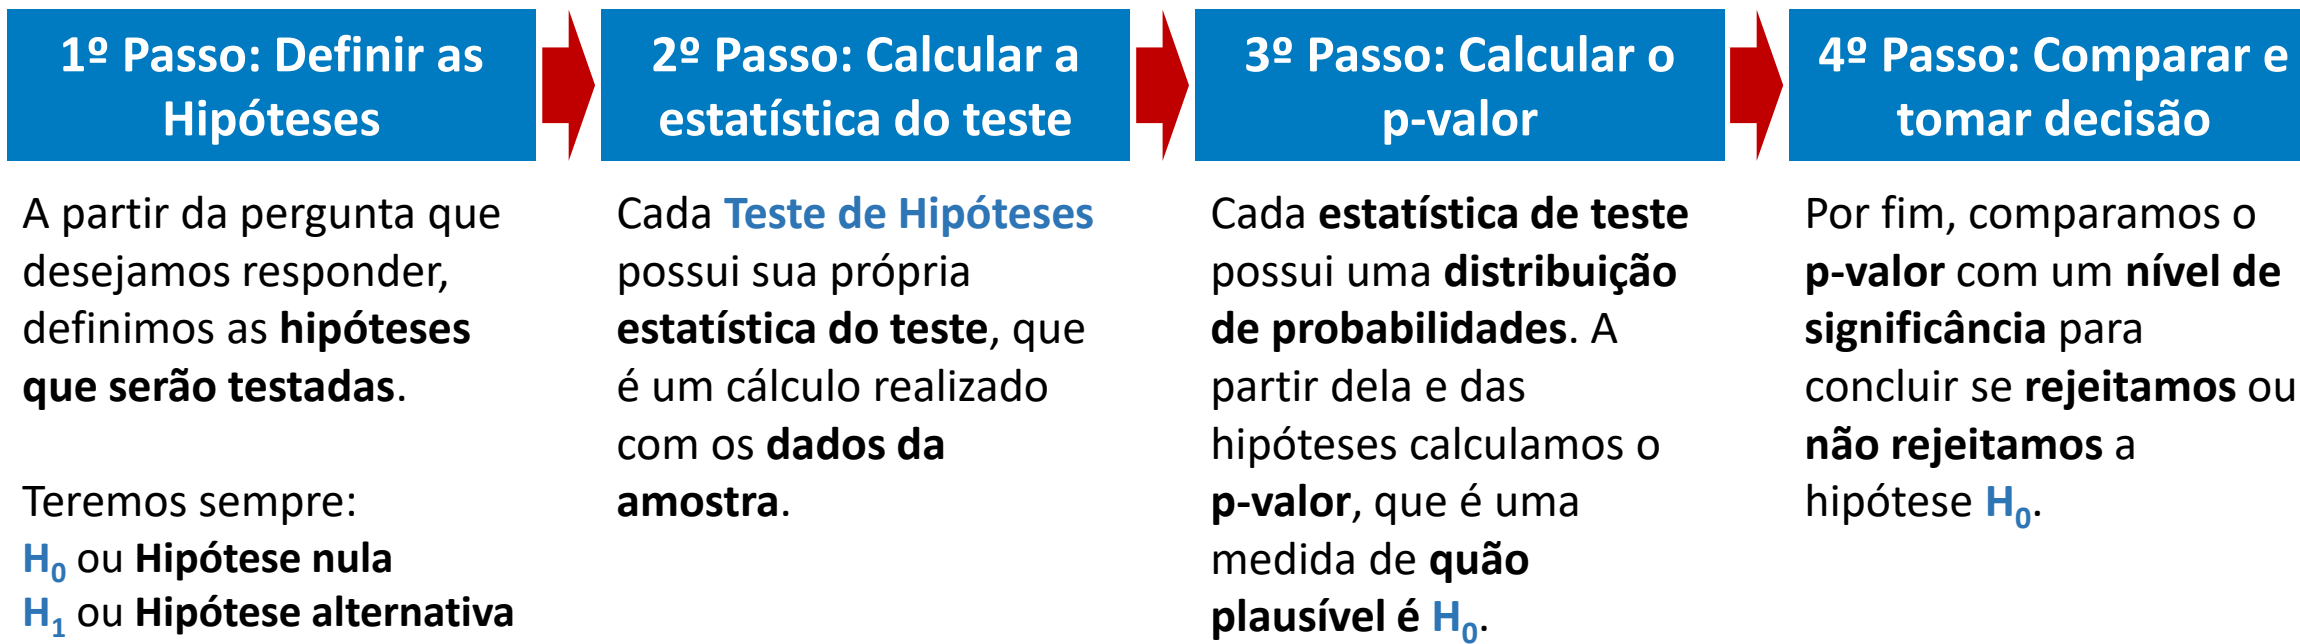


# Noções de Inferência Estatística

## Estrutura dos Testes de Hipóteses



Entender o conceito de cada passo te possibilitará utilizar qualquer **Teste de Hipóteses**, afinal existem muitos, cada um adequado para atender uma necessidade de análise.





Preditiva.ai

# Noções de Inferência Estatística

## Método Científico

O **Método Científico** é um processo utilizado para **construção de conhecimento** baseado em **5 principais etapas**:

### 1. Definição de uma questão


Pode ser algo muito específico: “Por que o céu é azul?” ou algo mais aberto: “Como aumento as vendas em Dezembro?”. Nesta etapa também são realizadas pesquisas para identificar **experimentos já realizados e conhecimento já existente**. Definir bem a questão é **fundamental** para o resultado do processo!



O **Método Científico** é um processo utilizado para **construção de conhecimento** baseado em **5 principais etapas**:

## 2. Formulação de uma hipótese

Uma hipótese é uma **explicação** ou uma **tentativa de resposta** a questão definida no passo anterior. **Ela precisa ser testável**, ou seja, deve ser possível realizar um experimento que **comprove a hipótese formulada ou a contrarie**.



Fonte: <https://xkcd.com/892/>

O **Método Científico** é um processo utilizado para **construção de conhecimento** baseado em **5 principais etapas**:

### 3. Previsão dos resultados

**Antecipe** o que acontecerá se a **hipótese estiver correta**. Podem haver várias previsões, e **quanto mais improvável que uma previsão esteja correta apenas por acaso, mais convincente ela será** caso se concretize. A evidência também é mais forte se a resposta para a previsão não for conhecida, pois evita o **viés de retrospectiva**.



Imagem: <https://www.subpng.com/png-c40cr1/>



O **Método Científico** é um processo utilizado para **construção de conhecimento** baseado em **5 principais etapas**:

#### 4. Teste ou Experimentação

Planeje um experimento para investigar se o **mundo real se comporta como previsto** na etapa 3. **Karl Popper** recomenda que os **cientistas tentem “derrubar” suas hipóteses**. Além disso, deve-se tomar todo o cuidado com **falhas que podem comprometer o resultado dos experimentos** como erros de medida, vieses humanos entre outros.



O **Método Científico** é um processo utilizado para **construção de conhecimento** baseado em **5 principais etapas**:

### 5. Análise dos resultados

Nesta última etapa deve-se **analisar os resultados da experimentação** e concluir se a hipótese definida na etapa 2 é refutada ou não. Se a **hipótese for refutada**, deve-se definir uma **nova hipótese**. Se os resultados da experimentação **suportam a hipótese atual**, mas as evidências não são fortes, deve-se **conduzir novos experimentos**.

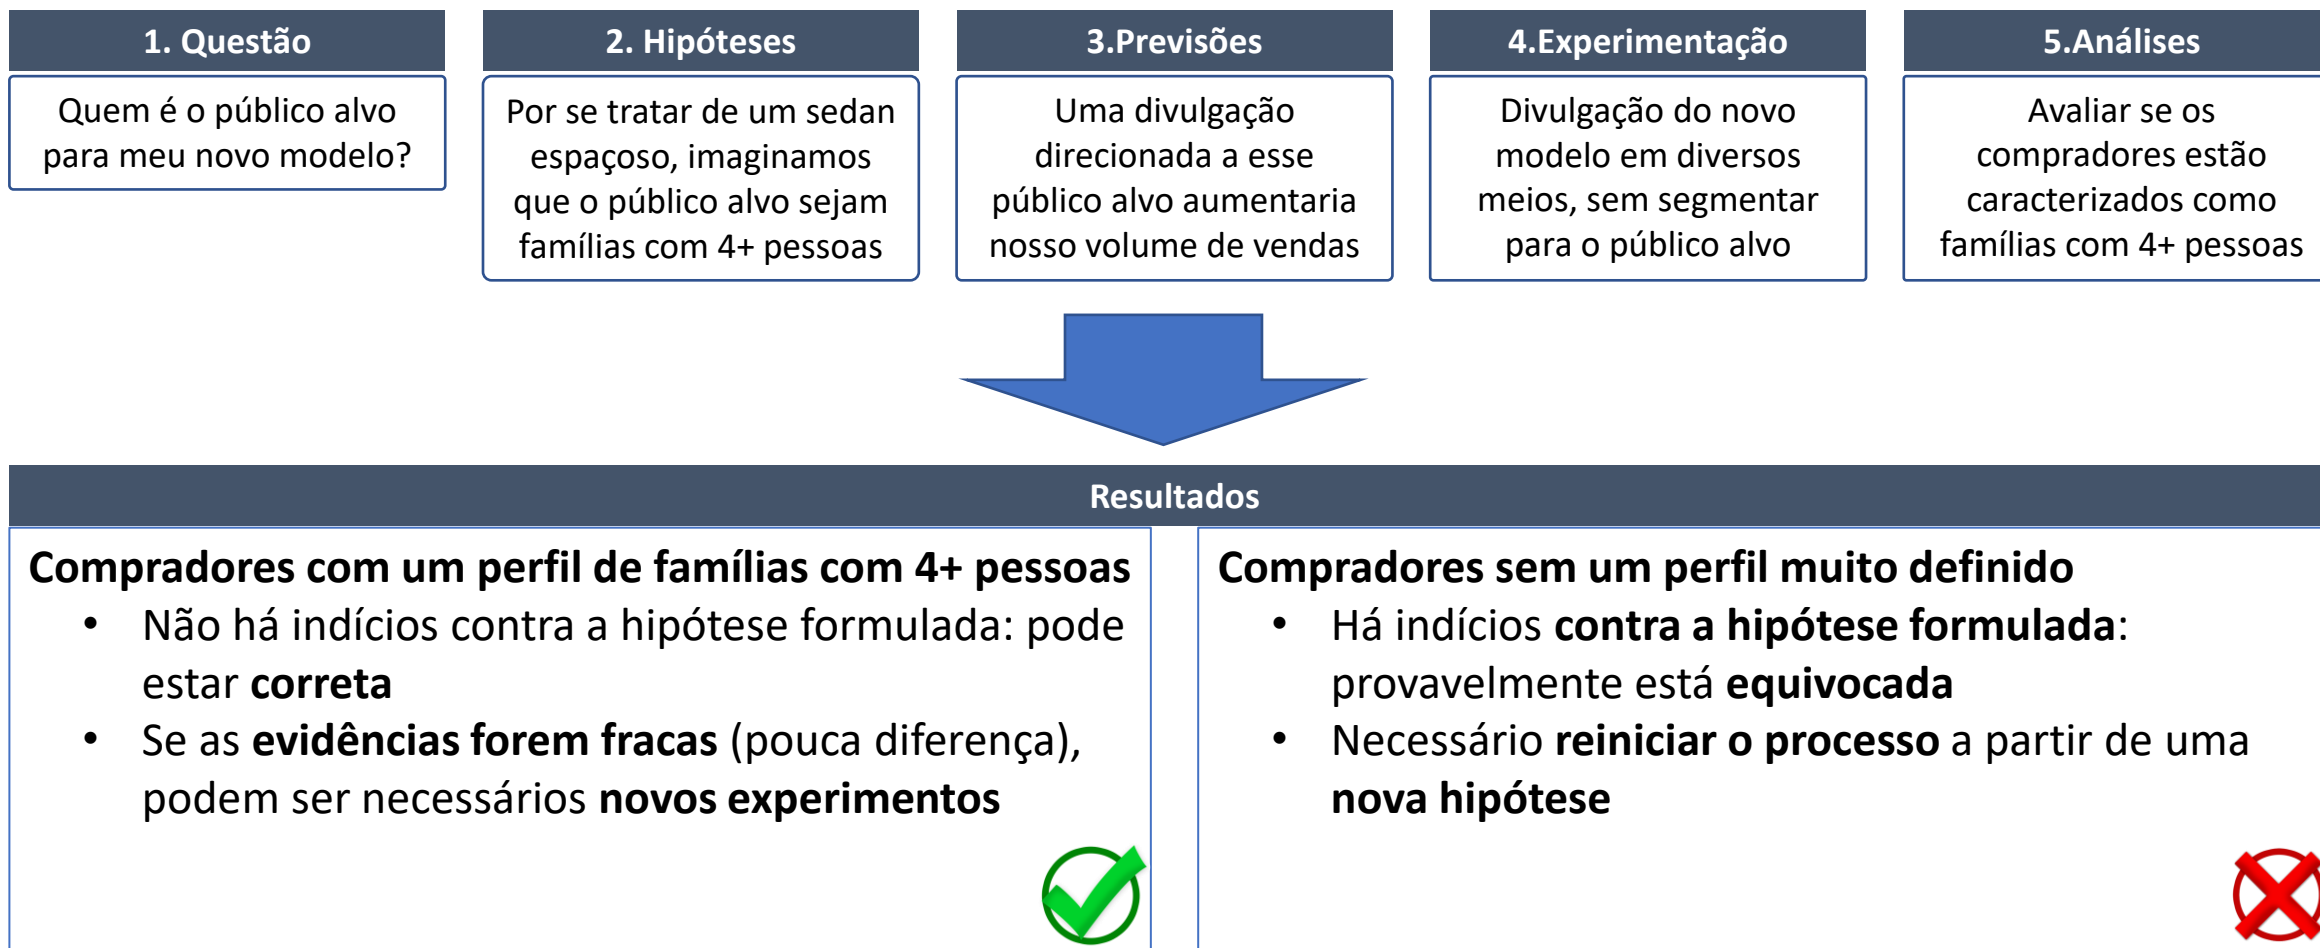


Vamos praticar a utilização do **Método Científico**:

Um fabricante de automóveis quer descobrir **quem é o público alvo para o seu novo modelo de veículo de passeio.**

Com essa informação ele poderá **concentrar seus recursos e esforços, e aumentar o volume de vendas** de seu produto para as pessoas que realmente têm **interesse na compra.**

### Exemplo de aplicação do **Método Científico**:



Principais **vantagens** da utilização do **Método Científico** em analytics:

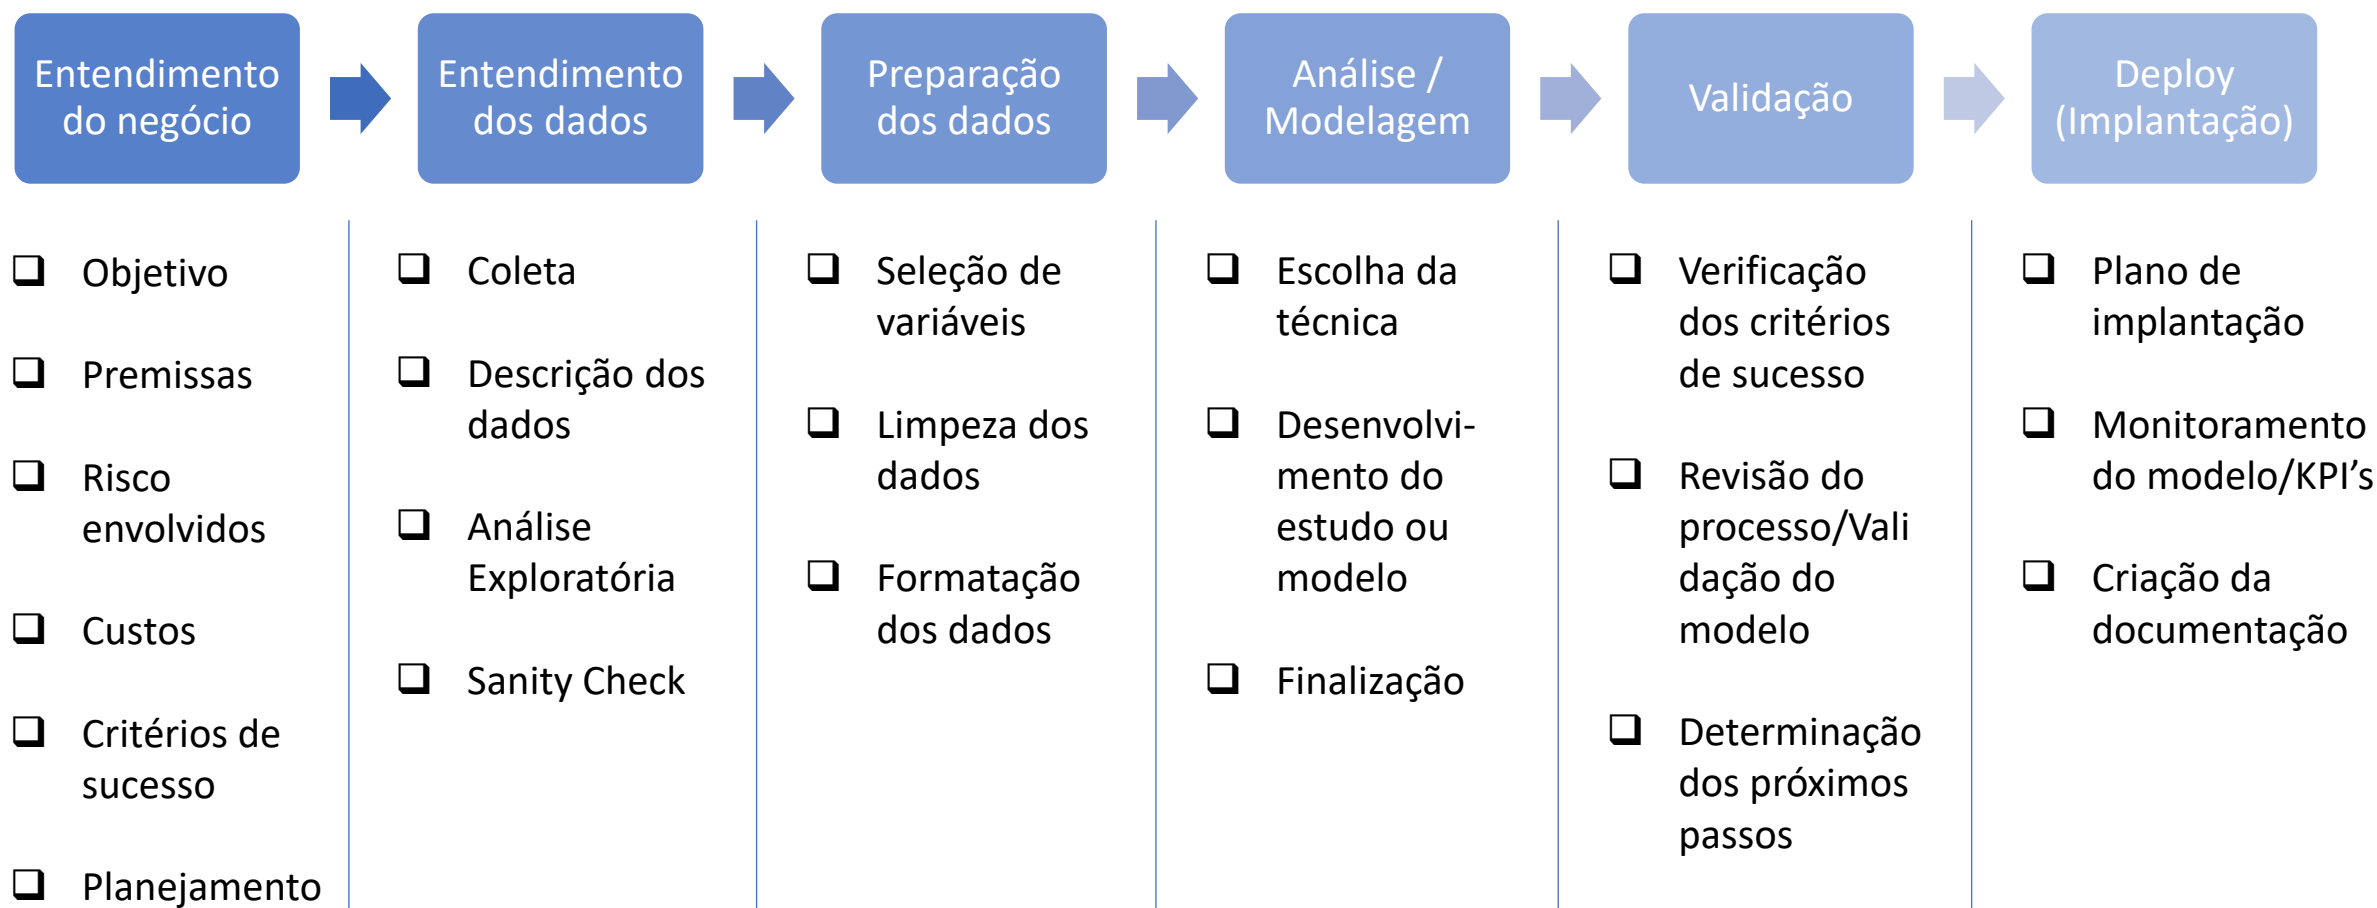
1. Baseado em **evidências empíricas** e não em “achismos”.
2. Permite **replicação dos resultados** por utilizar um **processo estruturado**.
3. É um **processo iterativo**, ou seja, as **respostas** para a 1ª questão podem gerar **novas questões**.
4. Construção **cumulativa de conhecimento**, ou seja, a cada iteração **novos conhecimentos são gerados**.

# Noções de Inferência Estatística

## Método Científico aplicado a Dados



Uma abordagem bastante utilizada para organizar o processo de análise de dados é **CRISP-DM**.





Preditiva.ai